ABSTRACT

บทคัดย่อ

สิ่งนี้เป็นมือที่น่าสนใจเสริมสร้างประสบการณ์เชิงโต้ตอบกัน สามารถประยุกต์ใช้ได้หลากหลาย เช่น Virtual Reality(VR) และการ Autonomous driving ซึ่งทำให้การโต้ตอบที่ซับซ้อนผ่านการสร้างการเคลื่อนไหวของมนุษย์ขึ้นมาใหม่ แม้ว่าจะมีความก้าวหน้าอย่างมาก การขับเคลื่อนด้วยDeeplearningเป็นการแสวงหาความสมจริงสูงสุด **ที่ต้องเผชิญหน้ากับปัญหา เช่น limited dataset diversity, lack of detailed hand representation , occlusions**

งานสำรวจนี้เป็นการทบทวนอย่างละเอียดเกี่ยวกับวิธีการDeeplearning ในชุดข้อมูลที่หลากหลาย , Loss function และตัวชี้วัดการประเมินที่ใช้จัดการกับความซับซ้อนของการสร้างมือที่ปฏิสัมพันธ์กัน

MainstreamกระแสหลักของAlgorithmในช่วง5ปีที่ผ่านมา ถูกจัดอย่างเป็นระบบ2กลุ่มหลัก

1. Explicit representation การแทนรูปแบบชัดเจน
parametric mesh , 3DGausian

2.Implicit representationการแทนรูปแบบเชิงนัยแสดงโครงสร้างโดยตรง
SignedDistanceFields(SDF) , Neural RadianceField(NeRF)

modelสมัยใหม่ที่ใช้กับในการแทนรูปแบบNovelDeeplearningแบบใหม่ graph convolutional network(GCN) โครงกระดูกของข้อมือ
โครงข่ายประสาท Transformerถูกนำมาใช้แก้ไขปัญหาก่อนหน้าในการสร้างมือขึ้นมาใหม่อย่างมีประสิทธิภาพ

เป็นงานสำรวจเฉพาะเจาะจงสำหรับการสร้างมือทั้ง2ข้างและมีการปฏิสัมพันธ์กับวัตถุ งานสำรวจนี้ประกอบด้วยแง่มุมที่หลากหลายเพื่อขยายขอบเขตมุมมอง นวัตกรรมในอนาคตและการใช้งานอย่างเป็นธรรมชาติ

Introduction

บทนำ



Applications of hand reconstruction: (a) hand rehabilitation [11];
(b) collaborative remote guiding [12];
(c) sword function gesture [13];
(d) gesture defined surface [14];
(e) digital puppetry [15]; (f) virtual keyboard tapping [16];
(g) intubation training [17].

การสร้างมือขึ้นมาใหม่สามารถแยกออกเป็นการประเมินค่าของรูปร่างมือและท่าทางของมือ เป็นสิ่งที่โฟกัสเป็นจุดสนใจของการวิจัย ขับเคลื่อนโดยความก้าวหน้าในDeeplearning ได้รับความสำคัญที่เยี่ยมสำหรับการใช้งานการโต้ตอบอย่างเป็นธรรมชาติที่สะท้อนความคล่องแคลวที่ละเอียดอ่อนของมือมนุษย์

ด้วยเหตุนี้การโต้ตอบและประสบการณ์เสมือนจริงเป็นทิศทางการวิจัยหลักในการสร้างมือขึ้นมาใหม่

การปฏิสัมพันธ์กับมือที่สร้างขึ้นมาใหม่ได้รับความสนใจเนื่องจากมีความสามารถที่ให้ความเป็นธรรมชาติที่มากขึ้นและรายละเอียดประสบการณ์การโต้ตอบในหลากหลายโดเมน
ในความเป็นจริงเสมือน(VR)และความเป็นจริงเสริม(AR)ช่วยผู้ใช้โต้ตอบอย่างเป็นธรรมชาติกับวัตุผ่านมือเสมือนในการรรีโมการทำงานระยะไกลทางการแพทย์

ดังนั้นจึงมีกระบวนการการดำเนินอุตสาหกรรมในสาขาหุ่นยนต์และระบบอัตโนมัติ
- การปรับปรุงอย่างการควบคุมอย่างแม่นยำและความสามารถในการปฏิบัติงานของมือหุ่นยนต์
- ความแม่นยำด้านการสร้างมือขึ้นมาใหม่ของมือทั้ง2ข้างสามารถมีนัยสำคัญที่เพิ่มพูนยกระดับด้านการปรับตัวแม่นยำในสภาพแวดล้อมที่เสมือนจริง

ด้วยเหตนี้การขยายขอบเขตการประยุกใช้ของการสร้างมือขึ้นมาใหม่ท่ามกลางแนวทางที่หลากหลายเพื่อบรรลุในการสร้างมือขึ้นมาใหม่ที่โดดเด่นนั้นที่ให้ผู้ใช้มีปฏิสัมพันธ์กับระบบและสภาพแวดล้อม**โดยไม่จำเป็นต้องติดอุปกรณ์กับร่างกาย** ทำให้ราคาไม่แพงมากขึ้นและอนุญาติการเคลื่อนไหวของนิ้วที่ไม่ถูกกจำกัด

ในช่วงเริ่มต้นสำหรับท่าทางของมือนั้นใช้การประมานเป็นหลักในการพึ่งพาที่ไม่ใช้Deeplearning สำหรับสถานการณ์ที่ซับซ้อน
การประมาณท่าทางของการสร้างมือขึ้นมาใหม่หันไปใช้Deeplearningเพื่อบรรลุความเสถียรของประสิทธิภาพให้โมเดลกดีขึ้น

โมเดลอย่าง convolution (CNNs) Transformer และ graph convolution network (GCNs) มีความเชี่ยวชาญที่เรียนรู้การสกัดกั้นและแสดงประสิทธิภาพที่เหนือกว่าเมื่อมีข้อมูลฝึกสอนจำนวนมาก

Section 2
Hand model representation

การแทนโมเดลมือ

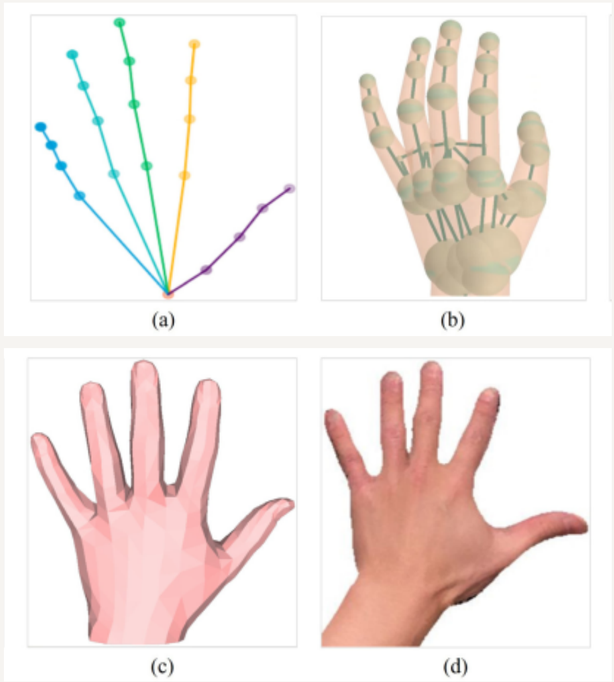
ในการวิจัยเริ่มต้นมีการศึกษาโมเดล parametric mesh อย่างลึกซึ้ง **ต่อมาจึงได้มีการกำเนิดโครงข่ายประสาทขึ้นมา implicit neural representations (INR)** เช่น occupancy field SDF และ NeRF

แสดงให้เห็นถึงความโดดเด่นในประสิทธิภาพในความนิ่งของฉากสำหรับสร้างภาพมุมใหม่
วิธีINRถูกนำไปใช้เพื่อสร้างความละเอียดและความแม่นยำของการสร้างมือมนุษย์ ดังนั้นหลักการการแทนโมเดลมืออย่างเป็นระบบ **สามารถแบ่งเป็น 2 ประเภทหลักๆ** คือ explicit และ implicit modeling

- Explicit modeling อธิบายรูปร่างของทรงเรขาคณิตต่างๆ โดยใช้จุด เส้นขอบ และพื้นผิวในการอธิบายโครงสร้างของมืออย่างชัดเจน
- Implicit modeling ใช้ฟังก์ชันหรือฟิลด์ในการแทนรูปร่างของมือ ซึ่งช่วยจัดการรูปทรงที่ซับซ้อนและรูปร่าง

2.1
Explicit Representation

การแทนรูปแบบมือเชิงชัดเจน



Hand model representations:
(a) skeleton representation [30];
(b) sphere-mesh model [31];
(c) MANO model [23];
(d) implicit representation [32],
where (a) (b) and (c) are explicit representations.

เป็นวิธีการแทนข้อมูลให้โดยตรงที่สามารถตีความได้และสามารถแสดงโครงสร้างของรูปทรงเรขาคณิตออกมาได้

ในบรรดาวิธีการเหล่านี้การแทนแบบโครงกระดูกถูกใช้งานอย่างทั่วไป โดยอยู่ภายใต้การกำหนดโครงสร้างข้อต่อของมือ ซึ่งทำให้ง่ายและมีประสิทธิภาพอย่างมาก

ในทำนองเดียวกัน meshแบบทรงกลม ให้การประมาณปริมาตรของมือโดยแทนมือเป็นกลุ่มของทรงกลมที่เชื่อมต่อกัน ซึ่งให้การแทนรูปร่างของมือในลักษณะหยาบ

นอกเหนือจากวิธีการแทนเหล่านี้ parametric mesh ได้รับการใช้งานอย่างแพร่หลาย เนื่องจากสามารถแทนการเปลี่ยนรูปของมือได้อย่างสะดวกสบาย

ในขณะที่โมเดล MANO ให้ parametric mesh สำหรับการแทนข้อมูลมือ โดยธรรมชาติที่รูปร่างโดยรวมค่อนข้างหยาบ ซึ่งไม่เพียงพอสำหรับการเก็บรายละเอียดระดับเล็กมาก เช่น ลวดลายผิวหนังและการเคลื่อนไหวของกล้ามเนื้อ เพื่อแก้ไขข้อจำกัดนี้ งานวิจัยล่าสุดด้านโมเดล parametric mesh จึงมุ่งเน้นไปที่การเสริมโครงสร้างของ MANO โดยเฉพาะในด้านการเพิ่มความละเอียด การเพิ่มรายละเอียดพื้นผิว และการแสดงผลกล้ามเนื้อให้สมจริงยิ่งขึ้น

DeepHandMesh เสนอวิธีแบบ weakly supervised เพื่อสร้าง มือที่สมจริง และสามารถเลียนแบบปฏิสัมพันธ์ทางกายภาพระหว่างส่วนต่าง ๆ ของมือได้
Chen และคณะ ปรับปรุง MANO โดยใช้ UV map ร่วมกับโครงข่าย super-resolution เพื่อเพิ่มรายละเอียดระดับสูง

อย่างไรก็ตาม **วิธีเหล่านี้ยังไม่จำลองได้อย่างสมบูรณ์ในมือมนุษย์ได้ เช่น รูปลักษณ์,ตำหนิ, การตกแต่งของคนบางคน,เครื่องประดับ** เพื่อแก้ไขช่องว่างนี้จึงมีการนำเสนอวิธีการแทนมือแบบเฉพาะบุคคลHTML เพิ่มความสมจริงของพื้นผิวในโมเดล MANO โดยการบันทึกลำดับภาพมืออย่างละเอียด และใช้เทคนิค structure from motion(SfM) เพื่อสร้างโมเดล 3 มิติ

2.2Implicit representation

การแทนโมเดลมือแบบเชิงนัย

Implicit representation

ในปัจจุบันimplicit modelแสดงให้เห็นถึงความสามารถที่เหนือกว่าในการแทนค่ารูปร่างและลักษณะด้วยรายละเอียดเชิงเรขาคณิต

- Grasping field เป็นผู้บุกเบิกที่ผสานSigned Distance Field(SDF)เข้ากับการปฏิสัมพันธ์ระหว่างมือและวัตถุ ส่งผลให้เกิดความสมเหตุสมผลในเชิงความหมายและทางกายภาพ

- HALO เสนอ implicit modelที่ขับเคลื่อนด้วยkeypointsโดยอาศัย occupancy fieldช่วยให้สามารถคำนวณอนุพันธ์ที่ถูกต้องตามหลักชีวกลศาสตร์
แตกต่างจากHALOที่เน้นโครงกระดูกเป็นศูนย์กลาง

- LISAได้ขยายโมเดล MANO โดยผสาน NeRF ทำให้สามารถคำนวณค่า SDF และสีจากภาพหลายมุมมองได้ NeRF รับภาพหลายมุมและcamera parametersเป็นข้อมูลนำเข้า จากนั้นNeRFใช้deep learning เพื่อนเรนเดอร์ภาพสมจริงจากมุมมองใหม่ สิ่งนี้เกิดขึ้นผ่านกระบวนการเรนเดอร์เชิงปริมาตรโดยรวมค่าความหนาแน่นของสีที่สุ่มตัวอย่างมาตามแนวรังสีของแต่ละpixelส่งผลให้ได้ภาพที่มีความสมจริงสูง

- LiveHand นำเสนอรูปภาพทีสมจริงแบบrealtimeผ่านการผสาน MANO กับ NeRFด้วยความละเอียดที่ต่ำ และใช้การสุ่มตัวอย่างด้วยการ super-resolution เทคนิคเพิ่มความละเอียด
ในทำนองเดียวกันChen และคณะใช้โมเดล MANO-HD เพื่อเพิ่มความแม่นยำของรูปทรง พร้อมใช้ occupancy field แบบคู่เฉพาะจุดและ shading field ที่คำนึงถึงการบังตัวเองของแสง เพื่อสร้างรายละเอียดรูปร่างและพื้นผิวเฉพาะบุคคล

วิธีการแทนค่าที่กล่าวมามักประสบปัญหาสัญญาณรบกวนที่เกิดจากกระบวนการสุ่มตัวอย่าง ส่งผลกระทบต่อคุณภาพการเรนเดอร์

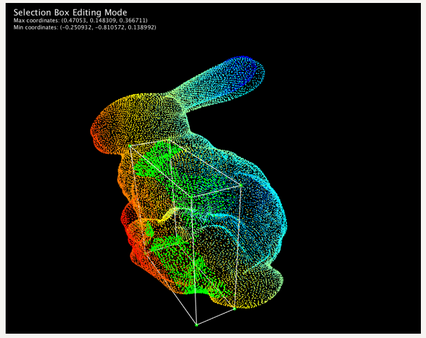
Implicit model แสดงให้เห็นของความสามารถในการรองรับความแตกต่างที่ซับซ้อนในรูปร่างของมือและตำแหน่งของมือ จึงทำให้สามารถปรับตัวได้ในหลากหลายในสถานการณ์ที่ไม่สามารถคาดการณ์ได้
แต่ถึงอย่างไรimplicit modelยังคงขาดการตีความโดยตรงที่แม่นยำอยู่จึงเผชิญหน้ากับอุปสรรค์การทำความเข้าใจและการวิเคราะห์ผลลัพธ์

2.3 Handmodel representationin current applications

การแทนโมเดลมือในงานประยุกต์ปัจจุบัน



Hololens



3D point clouds

ในปัจจุบันการทำแบบ explicit มีการใช้งานมากกว่าวิธีการแบบ implicit
modelโครงกระดูกมีประสิทธิภาพสูงด้านการทำงานแบบrealtimeและการคำนวณ โดยมีการใช้งานบ่อยๆ ในVR , ARสำหรับการติดตามมือและการโต้ตอบผ่านการการประมาณท่าทางของมือโดยมักจะใช้งานร่วมกับอวตารมือ

ในอีกด้านหนึ่ง การแทนค่าด้วย 3D point clouds ให้ความแม่นยำและรายละเอียดสูง จึงเหมาะกับงานที่ต้องการความแม่นยำสูง เช่น ระบบ motion capture

Phong surface เป็นวิธีที่เสนอการแทนค่าพื้นผิวแบบเรียบง่าย โดยใช้เทคนิคการปรับค่าเหมาะสมเพื่อให้โมเดลลู่เข้าสู่คำตอบได้รวดเร็ว เหมาะกับระบบประมวลผลภาพแบบrealtimeวิธีการนี้ถูกนำไปใช้งานในอุปกรณ์ Hololens เพื่อช่วยให้การปรับโมเดลสามมิติมีประสิทธิภาพมากขึ้น

วิธีการแทนค่าแบบexplicitที่กล่าวมาสามารถให้ข้อมูลรูปร่างมือและข้อต่อโดยตรง ซึ่งเหมาะสำหรับงานเชิงโต้ตอบ เช่น การรู้จำท่าทาง

แต่ว่าเนื่องจากข้อจำกัดในการทำงานแบบrealtimeคือความซับซ้อนในการคำนวณและความทนทานวิธีการแทนค่าแบบอื่น เช่น parametric mesh หรือ implicit representation จึงไม่ถูกนำมาใช้มากนักในงานจริง
จากข้อสังเกตดังกล่าว **สามารถสรุปได้ว่าการใช้งานในปัจจุบันมักเลือกใช้วิธีการแทนค่าโมเดลมือเพียงบางประเภท**ดังนั้น การเปรียบเทียบประสิทธิภาพของวิธีการแทนค่าต่าง ๆ อาจไม่สอดคล้องกับบริบทการใช้งานจริงในปัจจุบันอย่างสมบูรณ์

section3 Deeplearning-based interacting hands reconstruction

การสร้างมือที่มีปฏิสัมพันธ์กันโดยใช้ Deeplearning

ส่วนนี้ประกอบไปด้วยการวิเคราะห์และmonocularการส่องกล้องแบบเดี่ยวและภาพเชิงลึกและวิดีโอเป็นข้อมูลนำเข้า
พร้อมทั้งพิจารณาการสร้างโมเดลมือทั้งแบบ explicit และ implicit ดังนั้น
ผู้เขียนได้จำแนกวิธีการสร้างโมเดลมือออกเป็นสองกลุ่ม คือแบบ explicit และแบบ implicit ตามลักษณะการแทนค่า

- **วิธีแบบ model-based ใช้โมเดลมือแบบparametricหรือโครงกระดูกเพื่อควบคุมกระบวนการสร้างโมเดลมือ**

- **วิธีแบบ model-free จะเรียนรู้คุณลักษณะของมือโดยตรงจากข้อมูลนำเข้าเพื่ออนุมานโครงสร้างของมือ**

3.1 Explicit representation-based reconstruction

การสร้างมือโดยอาศัยการแทนแบบชัดเจน

วิธีในการสร้างโมเดลมือโดยพึ่งพาดารผสานstructural prior ความรู้เชิงโครงสร้างล่วงหน้า ดำเนินกระบวนการ**โดยการทำนายแนวทางนี้ช่วยให้ระบบทำงานได้ดีแม้มีข้อมูลจำกัดหรือมือถูกบังอย่างมาก** และยังสามารถสร้างท่าทางมือที่สม่ำเสมอและน่าเชื่อถือได้

อย่างไรก็ตาม โมเดลแบบparametricไม่สามารถแทนโครงสร้างและพื้นผิวมือที่ซับซ้อนได้อย่างแม่นยำ ส่งผลให้ความสมจริงของโมเดลที่สร้างลดลง

ในทางตรงกันข้าม **วิธีแบบไม่ใช้โมเดลมีความยืดหยุ่นสูงกว่า** ทำให้สามารถรองรับรูปร่างและท่าทางมือที่หลากหลายได้มากขึ้น

อย่างไรก็ตาม ประสิทธิภาพของวิธีแบบไม่ใช้โมเดลขึ้นอยู่กับความหลากหลายและความเป็นตัวแทนของชุดข้อมูลฝึกอย่างมาก

3.1.1 Model-based approach

แนวทางการสร้างมือแบบอิงโมเดล

01 one-stage

วิธีแบบขั้นตอนเดียวจะทำนายทั้งท่าทางและรูปร่างของมือในกระบวนการเดียว โดยไม่สร้างข้อมูลตัวกลางเพิ่มเติม

One-stage method คือวิธีแบบขั้นตอนเดียวสร้างคุณลักษณะจากภาพผ่านตัวเข้ารหัสตัวเดียวกันแต่แตกต่างในการถอดรหัส

Graph Convolutional Networks (GCN) เหมาะสำหรับการสร้างมือ เนื่องจากสามารถจัดการโครงสร้างกราฟที่ซับซ้อนของมือได้ดี และสามารถอนุมานข้อมูลที่หายไปจากการถูกบัง

Transformer ใช้กลไก self-attention เพื่อเรียนรู้ความสัมพันธ์ระยะไกลของส่วนต่าง ๆ ของมือ ทำให้สามารถแยกแยะบริเวณที่มีโครงสร้างคล้ายกันได้ แม้ในกรณีที่มือถูกบังอย่างหนาแน่น

MSMR-Net ใช้โครงสร้าง mesh หลายระดับความละเอียด โดยให้ mesh ความละเอียดสูงได้รับข้อมูลบริบทจาก mesh ความละเอียดต่ำ ช่วยให้การสร้างรูปมือมีรายละเอียดมากขึ้น

02 multi-stage

วิธีแบบหลายขั้นตอนจะแยกกระบวนการออกเป็นงานย่อยหลายส่วน และสร้างข้อมูลเสริมเพื่อช่วยให้การทำนายมีความแม่นยำมากขึ้น

Multi-stage method คือวิธีแบบหลายขั้นตอนยุคแรกของการทำนายรูปแบบข้อมูลตัวกลางของทั้ง2มือ จึงนำไปใช้ต่อในการกู้คืนMANO modelของโมเดลมือ ทำให้การทำนายมีความแม่นยำมากขึ้น

Segmentation mask มีข้อดีในการกำหนดขอบเขตของมืออย่างชัดเจน ซึ่งช่วยในการแยกมือออกจากฉากหลังและจัดการปัญหาการถูกบังได้ดี

2D heatmap ใช้แสดงการกระจายความน่าจะเป็นของตำแหน่งข้อต่อ และมีบทบาทสำคัญในการระบุตำแหน่งข้อต่อของมือ ข้อมูลตัวกลางทำเหล่านี้ทำหน้าที่เป็น prior ที่ให้ข้อมูล ซึ่งชี้นำกระบวนการปรับโมเดลให้เข้ากับข้อมูล

โดยเฉพาะเมื่อบางส่วนของมือไม่สามารถมองเห็นได้เนื่องจากการบังกันเองหรือการปฏิสัมพันธ์กับวัตถุ การผสานข้อมูลตัวกลางเหล่านี้ช่วยเพิ่มทั้งความทนทานและความแม่นยำของการสร้างมือขึ้นมาใหม่

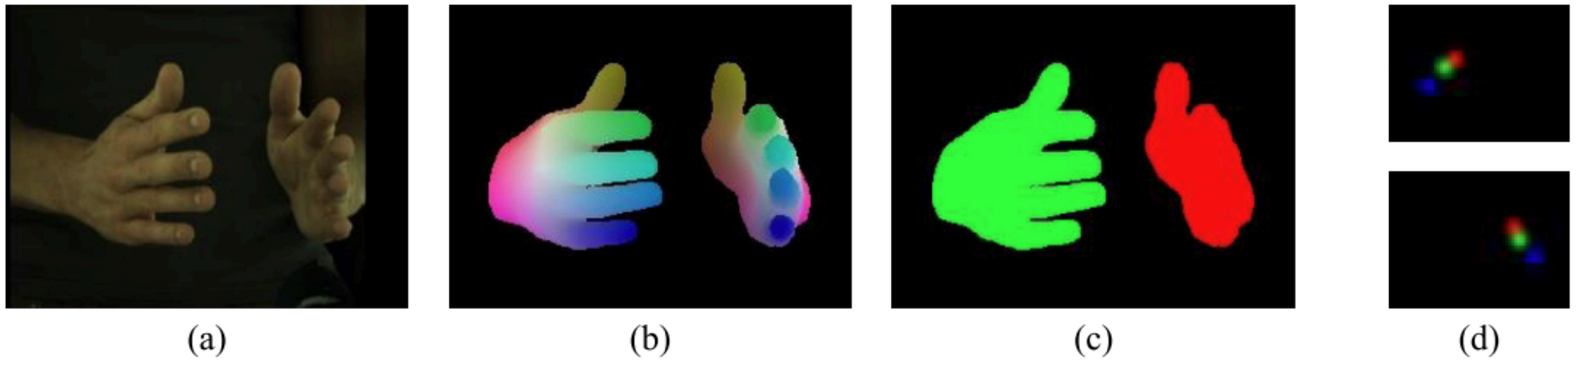
Multi-stage methods ใช้ข้อมูลตัวกลางหลายรูปแบบ เช่น dense map, segmentation mask และ 2D heatmap เพื่อช่วยนำทางกระบวนการสร้างมือ ทำให้โมเดลสามารถจัดการปัญหาการถูกบังและเพิ่มความแม่นยำได้ดีขึ้น แม้ว่าจะมีข้อจำกัดด้านความซับซ้อนและความคลาดเคลื่อนสะสมระหว่างขั้นตอน

3.1.2. Model-free approach

แนวทางการสร้างมือแบบไม่อิงโมเดล

ความกำกวมที่เกิดจากรูปลักษณ์ของมือและนิ้วที่มีความคล้ายกันมาก ถือเป็นความท้าทายหลักของงานสร้างมือที่ปฏิสัมพันธ์กันแบบไม่ใช้โมเดลเมื่อไม่มีความรู้โครงสร้างล่วงหน้า วิธีแบบ model-free ส่วนใหญ่จึงจำเป็นต้องผสานตัวแทนข้อมูลระหว่างทางเข้ามาใช้

Keypoint Transformer และ A2J-Transformer ใช้กลไก self-attention และ cross-attention เพื่อเชื่อมโยง keypoint กับข้อต่อ โดยไม่จำเป็นต้องบังคับให้ keypoint แต่ละจุดสอดคล้องกับข้อต่อแบบตายตัว
แม้ว่าวิธีเหล่านี้จะสามารถจับโครงสร้างเชิงพื้นที่ของมือได้ดี แต่ก็มีความไวต่อสัญญาณรบกวนในข้อมูลนำเข้า



Intermediary modalities in the multi-stage process:
(a) input image [48];
(b) dense map;
(c)segmentation mask;
(d) 2D heatmaps of the wrists.

3.2Implicit representation-based reconstruction

การสร้างมือโดยอาศัยการแทนแบบเชิงนัย

การสร้างมือขึ้นมาใหม่ด้วยimplicitมีการเปลี่ยนโครงสร้างมือที่ซับซ้อนที่ซับซ้อนให้เรียบง่ายขึ้น
วิธีนี้สามารถเก็บรายละเอียดเล็กๆและความผิดรูปตามธรรมชาติของมือ
เช่น รอยพับของผิวหนัง การงอของข้อต่อ ส่งผลให้โมเดลมีความสมจริงและแม่นยำมากขึ้น
ช่วยเพิ่มความถูกต้องและการใช้งานจริงของงาน
งานเหล่านี้เสนอวิธีใหม่ในการแก้ปัญหาความคล้ายกันของโครงสร้างมือ เปลี่ยนมุมมองงานสร้างมือ
เป็นการจำแนกจุด 3 มิติของมือที่มีปฏิสัมพันธ์กัน

Im2Hands ใช้ข้อมูลบริบทเพื่อแยกนิ้วที่อยู่ใกล้กัน ซึ่งมักเป็นปัญหาเพราะมือมีลักษณะคล้ายกัน

HandNeRF แยกท่ามือด้วย deformation field เพื่อเก็บรายละเอียดเฉพาะของแต่ละท่า

VA-NeRF เป็นงานแรกที่ใช้ NeRF กับมือจากภาพเดียวได้

สามารถนำไปใช้ในงานอื่น เช่น การรู้จำท่าทางมือ

3.3 State-of-the-art hand tracking in current VR/AR systems

เทคโนโลยีการติดตามการเคลื่อนไหวของมือบนVR/AR

เทคโนโลยีการติดตามการเคลื่อนไหวของมือระดับแนวหน้าที่ใช้ในระบบ VR/AR ปัจจุบัน
เนื่องจากช่วยให้ผู้ใช้สามารถโต้ตอบกับระบบได้อย่างเป็นธรรมชาติและเข้าใจง่ายมากขึ้น

ข้อมูลที่ผ่านการเตรียมแล้วจะถูกป้อนเข้าสู่อัลกอริทึมที่อาศัยการเรียนรู้ เพื่อประมาณรูปร่างและท่าทางของมือ

อย่างไรก็ตาม**วิธีเหล่านี้ยังมีข้อจำกัดด้านมุมมองการมองเห็น และไวต่อสภาพแสงของสิ่งแวดล้อม โดยมักทำงานได้แย่ลงในสภาพแสงน้อย**

https://www.ultraleap.com/

ประเด็นปัญหาของpaperฉบับนี้ที่ผู้ทำสนใจ

01

ความหลากหลายของชุดข้อมูลยังจำกัด (Limited dataset diversity)

- ชุดข้อมูลมือที่มีปฏิสัมพันธ์กันจริง ๆ ยังมีไม่มาก
- ไม่ครอบคลุมท่าทาง รูปร่างมือ บุคคล และสถานการณ์ที่ซับซ้อน

02

การแทนรายละเอียดของมือยังไม่สมจริงพอ (Lack of detailed hand representation)

- โมเดลแบบ parametric เช่น MANO ให้รูปร่างมือโดยรวม แต่ขาดรายละเอียดเล็ก ๆ
- เช่น รอยพับผิวหนัง กล้ามเนื้อ เครื่องประดับ ลักษณะเฉพาะบุคคล

03

ปัญหาการบังกันของมือและวัตถุ (Occlusions)

- มือสองข้างบังกันเอง
- มือบังวัตถุ หรือวัตถุบังมือ
- ทำให้การประมาณท่าทางและรูปร่างผิดพลาดได้ง่าย

04

ความยากในการสร้างมือสองข้างที่มีปฏิสัมพันธ์กันอย่างสมจริง

- ต้องคงความถูกต้องเชิงโครงสร้าง
- พร้อมความสมจริงทางภาพ
- และต้องรองรับการใช้งานจริง เช่น VR/AR แบบ realtime

รายละเอียดของปัญหา (Detail ของ paper)

ด้านการแทนโมเดลมือ (Hand Representation)

Explicit representation
โครงกระดูก, sphere mesh, parametric mesh (MANO)

- ข้อดี
  - ตีความง่าย
  - คำนวนเร็ว
  - เหมาะกับงาน realtime VR/AR
- ข้อเสีย
  - รายละเอียดพื้นผิวและความสมจริงต่ำ
  - ไม่สามารถแทนลักษณะเฉพาะบุคคลได้ครบถ้วน

Implicit representation
SDF, occupancy field, NeRF

- ข้อดี:
  - แทนรายละเอียดเชิงเรขาคณิตได้สูง
  - รูปร่างสมจริงกว่า
- ข้อเสีย
  - ตีความยาก
  - คำนวณซับซ้อน
  - มีสัญญาณรบกวนจากการสุ่มตัวอย่าง

รายละเอียดของปัญหา (Detail ของ paper)

ด้านวิธีการเรียนรู้ (Deep Learning-based Reconstruction)

Model-based

- ใช้ความรู้เชิงโครงสร้าง (structural prior) เช่น MANO
- ทนทานต่อ occlusion และข้อมูลจำกัด
- แต่ความสมจริงของพื้นผิวต่ำ

Model-free

- เรียนรู้จากข้อมูลโดยตรง
- รองรับรูปร่างและท่าทางที่หลากหลาย
- แต่พึ่งพาคุณภาพและความหลากหลายของ dataset สูง

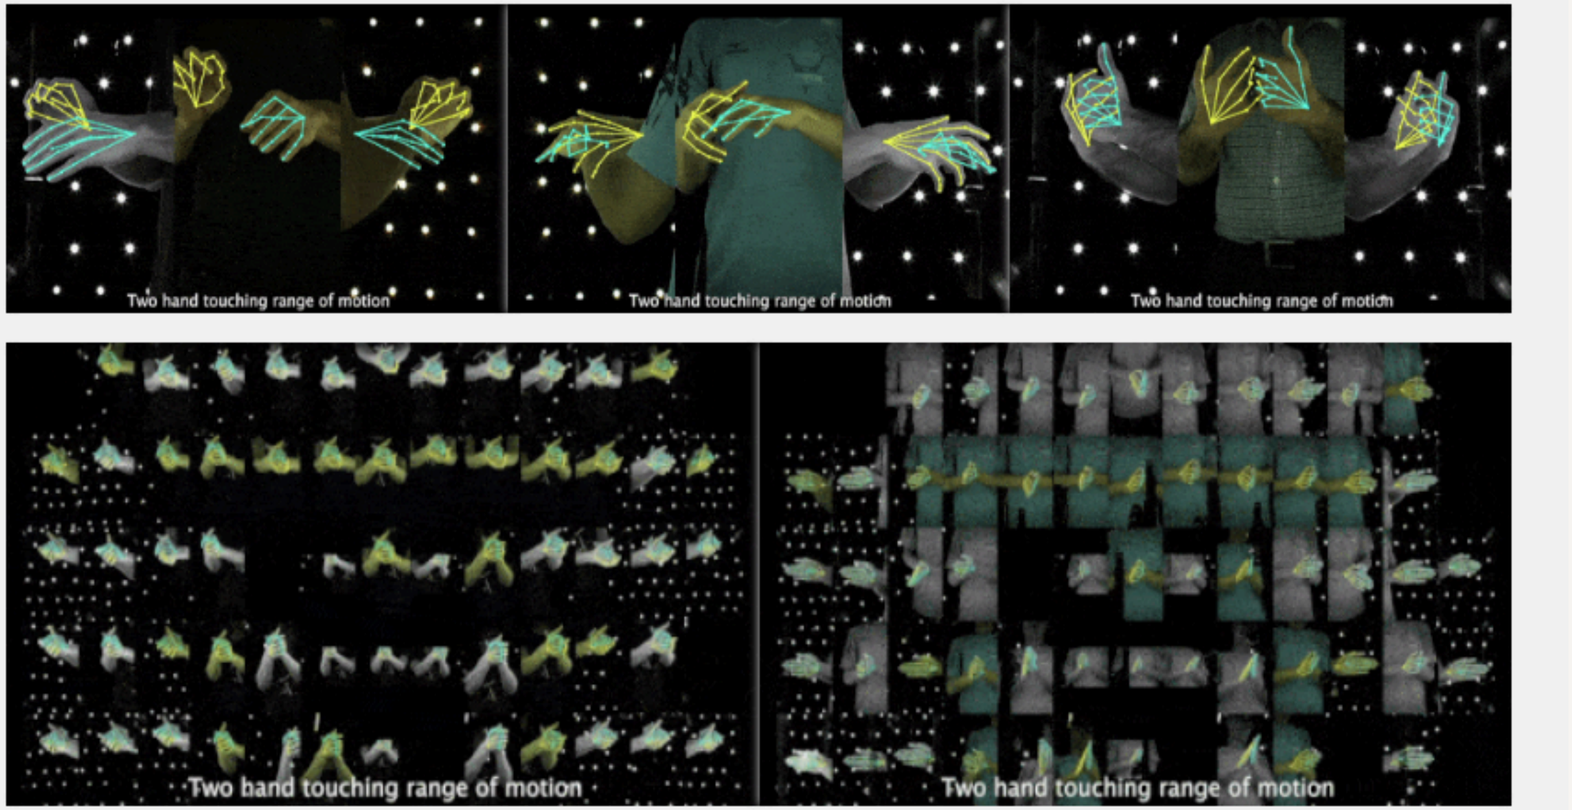
Dataset

- InterHand2.6M

Dataset หลักสำหรับงานมือสองข้างที่มีปฏิสัมพันธ์กัน
มีทั้ง 3D pose และ mesh annotation
ใช้เป็น benchmark ในหลายงาน
https://mks0601.github.io/InterHand2.6M/

- Ego-centric hand datasets

ใช้กับงานจากมุมมองบุคคลที่หนึ่ง
เหมาะกับ VR/AR และงานในสภาพแวดล้อมจริง
https://github.com/AlextheEngineer/Ego3DHands



Referenceที่น่าสนใจที่เกี่ยวข้อง(5 งาน)

- InterHand2.6M [48]
https://link.springer.com/chapter/10.1007/978-3-030-58565-5_33

งานวิจัยนี้เสนอชุดข้อมูล InterHand2.6M และโมเดลพื้นฐาน InterNet เพื่อแก้ปัญหาการประมาณท่าทางมือสองข้างที่มีปฏิสัมพันธ์กันจากภาพ RGB เดี่ยว โดยแสดงให้เห็นว่าการใช้ข้อมูลมือที่ปฏิสัมพันธ์กันช่วยเพิ่มความแม่นยำของการสร้างมือสามมิติได้อย่างชัดเจน

- MANO model [23]
https://scholar.google.com/scholar_lookup?title=Embodied%20hands%3A%20Modeling%20and%20capturing%20hands%20and%20bodies%20together&author=J.%20Romero&publication_year=2017

งานวิจัยนี้นำเสนอ MANO โมเดลมือแบบพารามิเตอร์ที่สามารถแทนท่าทางและการเปลี่ยนแปลงรูปร่างของมือได้อย่างสมจริง และเชื่อมต่อกับโมเดลร่างกาย SMPL เพื่อสร้างโมเดล SMPL+H ซึ่งสามารถสร้างการเคลื่อนไหวของร่างกายและมือร่วมกันได้อย่างเป็นธรรมชาติจากข้อมูล 4D

- DeepHandMesh [33]
https://link.springer.com/chapter/10.1007/978-3-030-58536-5_26

DeepHandMesh เป็นเฟรมเวิร์กการสร้าง hand mesh ความละเอียดสูงที่ใช้การเรียนรู้แบบ weakly-supervised โดยไม่ต้องพึ่ง ground truth mesh แต่ใช้ข้อมูลข้อต่อ 3 มิติและ multi-view depth แทน พร้อม loss function ที่ช่วยป้องกันการทะลุของ mesh ทำให้ได้ผลลัพธ์ที่สมจริงกว่าวิธีเดิม

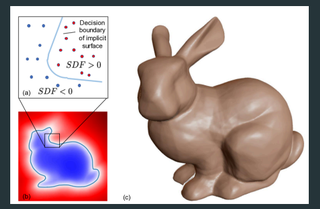
- HALO [43]
https://ieeexplore.ieee.org/document/9665895

เป็นการแทนค่ามือแบบใหม่ที่ใช้ 3D keypoints เป็นตัวขับเคลื่อน และสร้างพื้นผิวมือในรูปแบบ neural occupancy ซึ่งสามารถฝึกแบบ end-to-end และกำหนด loss บนพื้นผิวมือได้โดยตรง ส่งผลให้การสร้างท่ามือมีความสมจริงและสอดคล้องทางกายภาพมากขึ้น

- Neural Radiance Fields (NeRF) [26]
https://dl.acm.org/doi/abs/10.1145/3503250

NeRF เป็นการแทนฉากแบบ implicit โดยใช้โครงข่ายประสาทเทียมเรียนรู้ฟังก์ชันปริมาตร 5 มิติ และใช้ volume rendering เพื่อสร้างภาพมุมมองใหม่อย่างสมจริงจากภาพอินพุตจำนวนน้อย

Technical term (20 คำ)



Signed Distance Field (SDF)

1. Parametric Meshes
โมเดล 3D ที่ควบคุมรูปร่างด้วยพารามิเตอร์

2. 3D Gaussian Splatting
การแทนวัตถุด้วย Gaussian 3D เพื่อเรนเดอร์เร็ว

3. Signed Distance Field (SDF)
ฟังก์ชันบอกระยะของจุดถึงผิววัตถุ

4. Neural Radiance Field (NeRF)
โมเดลสร้างภาพ 3D จากหลายมุมมอง

5. Occupancy Field
ฟังก์ชันบอกว่าจุดอยู่ในหรืออยู่นอกวัตถุ

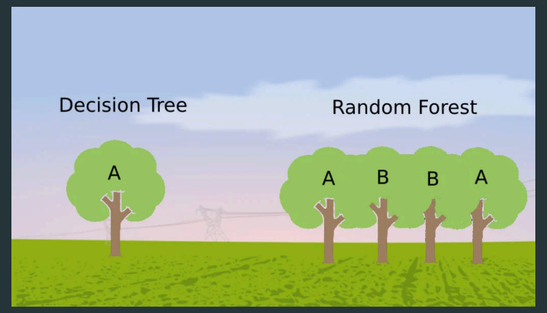
6. Occlusions
การบังกันของมือหรือวัตถุ

7. Loss Function
ฟังก์ชันวัดความผิดพลาดของโมเดล

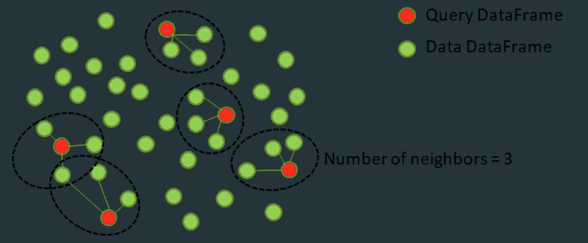
8. Graph Convolutional Network (GCN)
Neural network สำหรับข้อมูลแบบกราฟ

9. Decision Forest
อัลกอริทึมการตัดสินใจแบบหลายต้นไม้

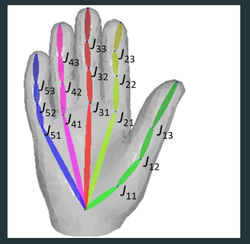
10. Nearest Neighbor
การทำนายจากข้อมูลที่ใกล้ที่สุด



Decision Forest



Nearest Neighbor

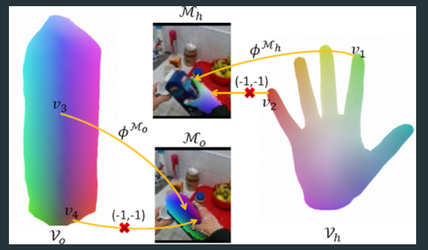


MANO model

11. Implicit Neural Representation (INR)
การแทนวัตถุด้วย neural network

12. Explicit Modeling
การแทนมือด้วยโครงสร้างชัดเจน

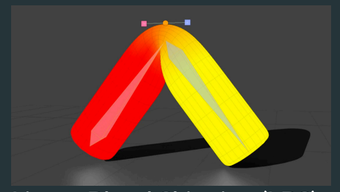
13. Implicit Modeling
การแทนมือด้วยฟังก์ชันต่อเนื่อง



Densemap

14. Model with Articulated and Non-rigid Deformations (MANO)
โมเดลมือมาตรฐานแบบ parametric

15. Linear Blend Skinning (LBS)
เทคนิคทำให้ผิวมือขยับตามข้อต่อ



Linear Blend Skinning (LBS)

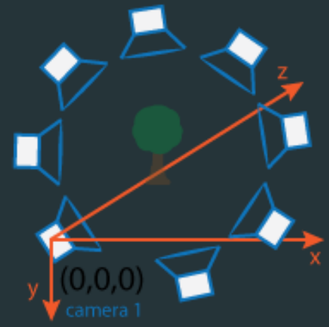
16. Weakly Supervised Learning
การเรียนรู้จาก label ที่ไม่สมบูรณ์

17. Structure from Motion (SfM)
การสร้าง 3D จากภาพหลายมุม

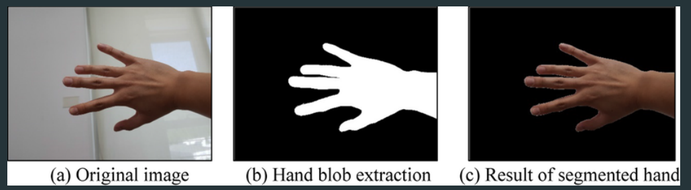
18. Phong Surface
โมเดลผิวแบบง่ายสำหรับเรนเดอร์เร็ว

19. Dense Map
แผนที่ข้อมูลระดับพิกเซลของมือ

20. Segmentation Masks
ภาพแยกมีออกจากพื้นหลัง



Structure from Motion (SfM)



Segmentation Masks